پروژه ی درس آمار

فاز یک

تاریخ تحویل: 12 آبان

ریحانه سلیمانی مقدم 403100151

تسک های مشترک:

- منشا داده و سازوکار جمع آوری:

منبع رسمی داده:

منبع اصلی داده‌ها، مرکز ملی هماهنگی آلزایمر آمریکا (National Alzheimer's Coordinating Center – NACC) است. این مرکز به‌عنوان مخزن متمرکز داده‌های حاصل از مراکز پژوهشی بیماری آلزایمر آمریکا (Alzheimer's Disease Research Centers – ADRCs) فعالیت می‌کند و داده‌های طولی، بالینی، شناختی، تصویربرداری و سایر اطلاعات مرتبط با بیماری آلزایمر و اختلالات مرتبط را گردآوری و در اختیار پژوهشگران قرار می‌دهد.

وب‌سایت رسمی NACC:

https://www.naccdata.org/about-nacc-data

دورهِ ی جمع آوری:

داده‌های مجموعه NACC (Uniform Data Set (UDS از سپتامبر ۲۰۰۵ به‌صورت طولی گردآوری شده‌اند. اطلاعات مربوط به هر Data Freeze شامل داده‌هایی است که تا یک بازه زمانی مشخص جمع‌آوری و به NACC ارسال شده‌اند. به‌روزرسانی و آرشیو داده‌ها به‌صورت دوره‌ای انجام می‌شود. با این حال، بازه زمانی دیتاست مورد استفاده در این پروژه لزوماً با کل بازه زمانی داده‌های NACC یکسان نیست. داده‌های در اختیار پروژهسعی کردم ستونی که دیتاهای زمانی رو نگه داشته باشه پیدا کنم ولی همچین ستونی یافت نشد . این بازه برای مجموعه داده‌های UDS و MRI مورد استفاده در پروژه یکسان در نظر گرفته شده است.

روش کلی تولید داده:

NACC داده‌های شرکت‌کنندگانی را گردآوری می‌کند که در مراکز پژوهشی بیماری آلزایمر آمریکا (ADRCs) مورد ارزیابی قرار می‌گیرند. شرکت‌کنندگان می‌توانند وضعیت‌های شناختی متفاوتی داشته باشند؛ از جمله افراد با عملکرد شناختی طبیعی، افراد دارای اختلال شناختی خفیف (MCI) و افراد مبتلا به دمانس.

اطلاعات UDS از طریق ارزیابی‌های استاندارد و ساختاریافته در مراکز ADRC جمع‌آوری می‌شود. این ارزیابی‌ها شامل اطلاعات جمعیت‌شناختی، سوابق پزشکی، وضعیت عملکردی، آزمون‌های شناختی و تشخیص‌های بالینی هستند. داده‌های تصویربرداری MRI نیز برای بخشی از شرکت‌کنندگان و در ارتباط با اطلاعات بالینی آنان در دسترس است.

از آنجا که روش جذب شرکت‌کنندگان در مراکز ADRC و در طول زمان متفاوت است، داده‌های NACC یک نمونه تصادفی و نماینده از کل جمعیت آمریکا محسوب نمی‌شوند. بنابراین، تعمیم نتایج حاصل از این داده‌ها به جمعیت عمومی باید با احتیاط انجام شود.

محدودیت دسترسی: داده‌های NACC به‌صورت رایگان برای پژوهشگران واجد شرایط در سراسر جهان قابل درخواست هستند؛ با این حال، دریافت داده‌ها مستلزم ثبت درخواست پژوهشی و پذیرش توافق‌نامه استفاده از داده‌ها (Data Use Agreement – DUA) است. دسترسی به فایل‌های داده از طریق فرایند رسمی درخواست و سامانه امن NACC انجام می‌شود.

نکته: با وجود آنکه منبع اصلی داده‌های این پروژه NACC است، دیتاست مورد استفاده در تحلیل‌ها، کل داده‌های موجود در NACC نیست. بنابراین ساختار فایل‌های این دیتاست ممکن است با مجموعه داده‌های کامل NACC متفاوت باشد. جزئیات دقیق مربوط به انتخاب شرکت‌کنندگان و... باید توسط دستیاران درس و مستندات همراه آن‌ها گزارش شود.

- ## واحد مشاهده و ساختار داده:

درمورد واحد مشاهده در کارت پروژه نیز گفتیم. ساختار داده نیز در فایل بررسی شده که داده نشان میدهد که فایل uds 1237 سطر دارد که شناسه های یکتایی اند و 180 ستون دارد مثل جنسیت ایدی سن و یکسری داده های کیفی دیگر است. و فایل mri شامل 1237 سطر متمایز و متناظر با فایل uds است و دارای 126 ستون از داده های اندازه ی بخش های مختلف مغزی است.

- نمونه گیری و انتخاب و قابلیت تعمیم:

بر اساس مستندات رسمی NACC، شرکت‌کنندگان در مجموعه UDS از طریق مراکز پژوهشی بیماری آلزایمر آمریکا (ADRCs) جذب می‌شوند. روش جذب در مراکز مختلف می‌تواند شامل ارجاع پزشک، معرفی داوطلبانه توسط فرد یا خانواده و جذب از طریق فعالیت‌های اجتماعی و جامعه‌محور باشد. بنابراین، روش جذب شرکت‌کنندگان در NACC مبتنی بر نمونه‌گیری تصادفی ساده از کل جمعیت آمریکا نیست و بین مراکز و در طول زمان تفاوت دارد.

با توجه به اینکه داده‌های NACC نمونه‌ای تصادفی و نماینده از جمعیت عمومی آمریکا نیستند و شرکت‌کنندگان از مراکز پژوهشی تخصصی جذب شده‌اند، تعمیم نتایج به کل جمعیت آمریکا یا تمام افراد مبتلا به بیماری آلزایمر باید با احتیاط انجام شود. علاوه بر این، دیتاست مورد استفاده در این پروژه زیرمجموعه‌ای از داده‌های NACC است بنابراین، محدودیت تعمیم‌پذیری ممکن است در این زیرمجموعه نیز وجود داشته باشد. در نتیجه، یافته‌های این پروژه در درجه نخست برای توصیف و بررسی روابط آماری در میان شرکت‌کنندگان موجود در دیتاست مورد استفاده معتبر هستند.

- طبقه بندی متغییر ها:

NACCID: شناسه شرکت کننده، شناسه ای و اسمی

SEX: جنیت شرت کننده، کیفی و اسمی

NACCAGE: سن شرکت کننده، کمی و نسبتی

NACCUDSS: وضعیت شناختی، کیفی و ترتیبی

MOCATOTS: امتیاز ازمون شناختی، کمی و ترتیبی

CDRSUM: مجموع امتیازات مقیاس clinical dementia rating sum boxes ، کمی گسسته و ترتیبی

MACATOTS: امتیاز کل ازمون MoCA میشه تحلیل صورت ترتیبی بو که امتیازی گسسته کمی

LH_ENTORHINAL_GVOL: حجم ماده خاکستری ناحیه انتورینال نیمکره چپ مغز، کمی پیوسته، نسبتی

میانگین ضخامت قشر ناحیه انتورینال چپ، کمی پیوسته و نسبتی :LH_ENTORHINAL_AVGTH
حجم ماده خاکستری ناحیه انتورینال نیمکره راست مغز، کمی پیوسته، :RH_ENTORHINAL_GVOL
نسبتی
میانگین ضخامت قشر ناحیه انتورینال راست، کمی پیوسته و نسبتی :RH_ENTORHINAL_AVGTH
سایر متغیر های حجمی و یا ضخامت قشری MRI: کمی پیوسته و نسبتی

- ممیزی کیفیت داده ها:

میان متغییر های اصلی تنها mocatots دارای کد غیرعادی 88 بود که خارج از بازه باقی داده ها بود و من اون رو به عنوان داده ی از دست رفته در نظر گرفته و چون 4 تا میان 1237 تا ردیف درصد کمی رو تشکیل میداد تصمیم به حذف اون ردیف های دارای داده ی از دست رفته گرفتم.

- جدول فراوانی و توزیع تجربی:

برای متغیرهای طبقه‌ای، جدول فراوانی و درصد هر طبقه تهیه می‌شود تا ترکیب نمونه و فراوانی گروه‌ها مشخص شود. برای متغیرهای کمی، خلاصه‌ی توزیع شامل شاخص‌های مرکز و پراکندگی و نمودارهای توزیع ارائه می‌شود. هدف، شناسایی الگوهای مهم مانند عدم توازن گروه‌ها، تمرکز داده‌ها، چولگی و وجود مقادیر پرت است تا ویژگی‌های اصلی داده‌ها بهتر درک شوند.

- مرکز و پراکندگی:

پراکندگی و مرکز همه ی متغییر های اصلی رسم شده است و نمودار های پراکندگی نیز رسم شده اند. برای متغیرهای کمی، میانگین و میانه به‌منظور بررسی مرکز توزیع، و انحراف معیار، چارک‌ها و دامنه‌ی بین‌چارکی برای سنجش پراکندگی داده‌ها گزارش می‌شوند. میانگین و انحراف معیار در توزیع‌های تقریباً متقارن مناسب‌اند، درحالی‌که میانه و دامنه‌ی بین‌چارکی در حضور چولگی یا داده‌های پرت، معیارهای مقاوم‌تری هستند. این شاخص‌ها به درک الگوی توزیع و میزان تغییرپذیری متغیرها کمک می‌کنند.

- مصورسازی درست:

انجام شده است.

- مقایسه توصیفی اولیه:

نمودار مقایسه ی پراکندگی سن با توجه به 4 وضعیت شناختی
و نمودار مقایسه ی ضخامت قشر انتوریال چپ مغز با توجه به 4 وضعیت شناختی نیز رسم شده است.

- نهایی کردن سوال آماری:

آیا بین وضعیت شناختی و امتیاز عملکرد شناختی افراد با شاخص‌های ساختاری قشر انتوریال مغز، شامل حجم و ضخامت قشر انتوریال در نیمکره‌های چپ و راست، رابطه‌ای وجود دارد؟

سوالات مسیر ج

- نقشه ی زیرمجموعه ی uds و mri:

در بالا متغییر ها تعریف شده اند.

جمعیت‌شناختی: سن و جنسیت تشخیصی: وضعیت شناختی شناختی: امتیاز MoCA عملکردی: CDR Sum، حجم ماده‌ی خاکستری قشر انتوریال چپ و راست بر حسب میلیمتر مکعب، میانگین ضخامت قشر انتوریال چپ و راست بر حسب میلیمتر

با توجه به گستردگی مجموعه‌داده و تعداد زیاد متغیرها، در این پروژه متغیرهای مرتبط با سؤال پژوهش انتخاب و دسته‌بندی شدند.

- ساختار شرکت کننده مراجعه:

با توجه به زیرمجموعه ی ارسالی و بررسی های انجام شده شناسه ها یکتا اند و ستونی درمورد اینکه تاریخ هر مراجعه چیست در دسترس نیست.

- اتصال uds و mri:

انجام شده است.

- داده های گمشده و انتخاب شدن نمونه چند وجهی: درصد گمشدگی متغییر های اصلی محاسبه شده است. و اینکه داده های uds و mri تناظر یک به یک داشتند در نتیجه دسترسی به اینکه افراد بدون mri چه تفاوتی دارند نبود.

- خلاصه مشترک شناختی تصویر برداری: نمایش داده شده است بین نمودار ها

اطلاعات کارت پروژه:

- مجموعه داده و زیرمجوعه مورد استفاده:
- عنوان موقت پروژه:

بررسی تفاوت ضخامت قشر انتورینال سمت چپ مغز در گروه‌های مختلف وضعیت شناختی با استفاده از داده‌های NACC

- سوال آماری اصلی:

ضخامت قشر انتورینال سمت چپ مغز (`LH_ENTORHINAL_AVGTH`) در گروه‌های مختلف وضعیت شناختی (`NACCUDSD`) چه تفاوتی دارد؟

(با توجه به اینکه آشنایی من با داده‌های پزشکی و متغیرهای بالینی محدوده، این سؤال در مرحله ی اولیه قرار داره. پس از بررسی تعریف متغیرها، کدهای مربوط به وضعیت شناختی و نحوه ی آماده‌سازی داده‌ها، ممکن است سؤال پژوهش اصلاح یا دقیق‌تر بشه.)

- واحد مشاهده:

داده‌های UDS در مجموعه‌ی NACC می‌توانند ساختار طولی داشته باشن؛ به این معنا که یک شرکت‌کننده ممکنه در مراجعه‌های مختلف چندین بار ارزیابی شده باشه. بنابراین، در داده‌های اصلی، هر سطر ممکنه نماینده ی یک مراجعه باشه، نه لزوماً یک فرد مستقل و ممکن است با چند ایدی یکسان در سطر ها مواجه شویم.

با این‌حال، بررسی اولیه ی فایل‌های آماده‌شده توسط دستیاران درس نشون می‌ده که هر فایل شامل ۱۲۳۷ شناسه‌ی یکتای `NACCID` است و مجموعه‌ی شناسه‌های دو فایل با یکدیگر مطابقت داره. در نتیجه، در فایل‌های فعلی هر شرکت‌کننده فقط یک بار ظاهر شده. (میتوانید بررسی های انجام شده برای این کار را در فایل alzheimer_phase1.ipynb مشاهده کنین)

هنوز مشخص نیست این یکتاسازی توسط دستیاران درس چطور انجام شده؛ در نتیجه ما فرض میکنیم که هر داده برای یک شرکت کننده ی مستقل است و فرضی هم درمورد اینکه مراجعه ی چندم است انجام نمیدهیم.

- جمعیت قابل تفسیر:

داده‌های NACC از شرکت‌کنندگان مراکز پژوهشی مرتبط با بیماری آلزایمر و اختلالات شناختی در ایالات متحده گردآوری می‌شوند. این نمونه لزوماً نماینده‌ی کل جمعیت ایالات متحده، همه‌ی سالمندان یا همه‌ی افراد دارای اختلالات شناختی نیست؛ زیرا شیوه‌ی جذب شرکت‌کنندگان و ویژگی‌های افرادی که در مراکز پژوهشی حضور پیدا می‌کنند ممکن است با جمعیت عمومی متفاوت باشه.

از آنجا که تحلیل حاضر بر شرکت‌کنندگانی متمرکز است که داده‌های UDS و MRI آن‌ها در فایل‌های آماده‌شده موجود است، احتمال دارد این افراد با شرکت‌کنندگانی که داده‌ی MRI ندارند تفاوت داشته باشند. در نتیجه، نتایج ممکن است به تمام شرکت‌کنندگان NACC نیز قابل تعمیم نباشه. (بنابراین، اگر در نمونه‌ی تحلیل‌شده تفاوتی بین گروه‌های وضعیت شناختی مشاهده شود، می‌توان آن را به‌عنوان یک تفاوت توصیفی در این نمونه گزارش کرد؛ اما تعمیم آن به جمعیت‌های بزرگ‌تر نیازمند بررسی بیشتر روش نمونه‌گیری، معیارهای انتخاب افراد و تفاوت‌های احتمالی میان افراد واردشده و واردنشده به تحلیل است. همچنین، مشاهده‌ی تفاوت آماری به‌تنهایی رابطه‌ی علت و معلولی را اثبات نمی‌کند.)

- متغییرهای اصلی و مقیاس اندازه گیری و نقش متغییر:

-`NACCID`: متغییر شناسایی کننده، شناسه‌ی شرکت‌کننده که برای شناسایی و تطبیق رکوردهای یک فرد در فایل‌های مختلف استفاده می‌شود. این متغیر اسمی و شناسایی‌کننده است و معنای کمی ندارد.

این متغییر به صورت 1237 استرینگ یکتاست که به صورت NACC123456 ذخیره شده است.

- `NACCUDSD`: متغیر گروه بندی مربوط به وضعیت شناختی ثبت‌شده در داده‌های UDS که قرار است برای دسته‌بندی شرکت‌کنندگان استفاده شود.

1: Normal congnition نرمال

2: Impaired-not-MCI اختلال شناختی کم

3: اختلال شناختی MCI

4: زوال عقل Dementia

- `LH_ENTORHINAL_AVGTH`: متغیر کمی اصلی مربوط به اندازه‌گیری میانگین ضخامت قشر انتورینال سمت چپ مغز در داده‌های MRI. که به صورت میلی متر تا سه رقم اعشار ثبت شده است.

مقیاس: بازه ی عددی بین صفر تا 4265 است که مقدار ضخامت قشر رو میگه.

- `NACCAGE`: متغیر توصیفی کمکی، مربوط به سن شرکت‌کننده که می‌تواند برای توصیف نمونه و بررسی تفاوت‌های احتمالی سنی بین گروه‌ها استفاده شود.

مقیاس: طبق دیتاها بازه ی عددی بین 41 الی 91 سال است.

(در صورت نیاز، پس از بررسی داده‌ها می‌توان متغیرهای دیگری را نیز برای توصیف نمونه یا بررسی محدودیت‌های تحلیل اضافه کرد.)

- نوع سوال:

سؤال اولیه از نوع توصیفی و مقایسه‌ای است.در این مرحله، هدف توصیف توزیع ضخامت قشر انتورینال سمت چپ و مقایسه‌ی شاخص‌هایی مانند میانگین، میانه و پراکندگی آن در گروه‌های مختلف وضعیت شناختی است.

- فرضیه اولیه:

فرض اولیه این است که توزیع ضخامت قشر انتورینال سمت چپ ممکن است در گروه‌های مختلف وضعیت شناختی متفاوت باشد. که نقطه شروع تحلیل است.

- محدودیت های اولیه:

1. محدودیت در تعمیم‌پذیری:

نمونه‌ی پژوهشی NACC لزوماً نماینده‌ی جمعیت عمومی نیست؛ بنابراین، تعمیم نتایج به همه‌ی سالمندان، همه‌ی افراد دارای اختلال شناختی یا کل جمعیت ایالات متحده نیازمند احتیاط است.

2. نامشخص‌بودن روش آماده‌سازی داده‌ها:

روش انتخاب یا یکتاسازی رکوردهای هر شرکت‌کننده در فایل‌های آماده‌شده هنوز مشخص نیست. این موضوع می‌تواند بر تفسیر واحد مشاهده و نتایج اثر بگذارد.

3.احتمال وجود داده‌های گمشده یا مقادیر جایگزین‌شده:

نام فایل `udslong_imputed.csv` احتمال انجام فرایند جایگزینی داده‌های گمشده را مطرح می‌کند، اما روش، متغیرهای مشمول و مقادیر جایگزین‌شده باید بررسی شوند. همچنین، کدهای خاصی که ممکن است به‌جای داده‌ی گمشده استفاده شده باشند باید شناسایی شوند.

4.احتمال تفاوت افراد دارای MRI با سایر شرکت‌کنندگان:

افرادی که داده‌ی MRI آن‌ها موجود است ممکن است از نظر ویژگی‌های بالینی یا جمعیت‌شناختی با افرادی که داده‌ی MRI ندارند متفاوت باشند. بررسی این تفاوت‌ها برای ارزیابی محدودیت انتخاب نمونه ضروری است.

5.نامشخص‌بودن هم‌زمانی اندازه‌گیری‌ها:

باید بررسی شود که وضعیت شناختی و اندازه‌گیری MRI هر شرکت‌کننده به چه زمان‌هایی مربوط هستند و آیا می‌توان آن‌ها را به‌صورت معنادار با یکدیگر مقایسه کرد

6. محدودیت در تفسیر رابطه:

حتی در صورت مشاهده‌ی تفاوت بین گروه‌ها، عوامل دیگری مانند سن یا سایر ویژگی‌های شرکت‌کنندگان ممکن است در تفاوت‌های مشاهده‌شده نقش داشته باشند. بنابراین، نتایج توصیفی به‌تنهایی برای نتیجه‌گیری علّی کافی نیستند.