پروژه ی آمار

فاز دوم

ریحانه سلیمانی مقدم

403100151

تسک های مشترک:

1. تعریف رویداد ها و متغیرهای تصادفی:

- رویداد A: قرار داشتن فرد در گروه دارای اختلال شناختی خفیف(NACCUDSD = 3)

A = {i : NACCUDSD(i) = 3}

- رویداد B: قرار داشتن فرد در گروه دمانس(NACCUDSD = 4)

B = {i : NACCUDSD(i) = 4}

- رویداد C: سن فرد بالای 75 سال باشد.

C = {i : NACCAGE(i) >= 75}

- رویداد D: ضخامت قشر انتوریال سمت راست کمتر از میانه ی نمونه ها باشد.

$$D = \{i: RH_ENTORHINAL_AVGT(i) < Median(RH_ENTORHINAL_AVGTH)\}$$

- متغییر تصادفی X: ضخامت قشر انتوریال سمت چپ مغز برای یک فرد تصادفی از افراد مجموعه NACC

X = LH_ENTORHINAL_AVGTH

2.احتمال های حاشیه ای و مشترک: رویداد C و D رو انتخاب میکنیم

- N = 1233
- nC = 271
- nD = 614
- nCD = 182

یعنی مراجعه کنندگانی که سن بالای 75 سال دارند و همچنین مقدار ضخامت قشر انتوریال راست انها کمتر از میانه باشد.

- P(C) = nC/ N = 271 / 1233 = 0.2198
- P(D) = nD / N = 614 / 1233 = 0.4980
- P(CD) = nCD / N = 182 / 1233 = 0.1476

3.احتمال شرطی:

- P(D|C) = P(CD) / P(C) = 0.6715
- P(C|D) = P(CD) / P(D) = 0.2964

با شرط کردن روی گروه سنی بالای ۷۵ سال، احتمال کمتر بودن ضخامت قشر انتورینال راست از میانه از 49.8% به 67.15% افزایش می‌یابد؛ یعنی این ویژگی در گروه سنی مذکور فراوان‌تر است. از سوی دیگر، با شرط کردن بر ضخامت کمتر از میانه، احتمال سن بالای ۷۵ سال بودن به 29.64% می‌رسد که نشان می‌دهد شرط‌گذاری بر ویژگی‌های مختلف، احتمال رویداد موردنظر را تغییر می‌دهد.

4.بررسی مفهوم استقلال:

- بررسی استقلال برای رویداد های C و D با توجه به مفهوم احتمال شرطی برای متغیر های مستقل که واضح است اما میتوانیم از ازمون استقلال استفاده کنیم و برابری

P(C) * P(D) = P(CD)

رو بررسی کنیم که با توجه به مقادیر یافت شده

P(C)*P(D) = 0.1095

که این مقدار مخالف مقدار P(CD) است.

- حدس میزنیم که رویداد C با رویداد E احتمالا استقلال بالاتری داشته باشند.

E= رویداد مرد بودن مراجعه کننده

E = {i : NACCSEX = 1}

nE=497 nCE= 117

P(E) = nE/N = 0.4031

P(EC) = nEC / N = 0.0949

P(E)*P(C) = 0.0886

از آنجا که $P(E \cap C) = 0.0949$ با حاصلضرب $P(E)P(C) = 0.0886$ اختلاف کمی دارد، می‌توان گفت دو رویداد مرد بودن مراجعه‌کننده و داشتن سن حداقل ۷۵ سال، در این نمونه به استقلال نزدیک هستند. با این حال، چون این دو مقدار دقیقاً برابر نیستند، استقلال کامل برقرار نیست.

5. توزیع گسسته و مدل دو جمله ای:

- مدل دو جمله ای:

n: تعداد آزمایش‌ها یا افراد نمونه

p: احتمال وقوع رویداد در هر آزمایش

X: تعداد دفعات وقوع رویداد

تابع احتمال مدل دوجمله‌ای:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

فرض‌های مدل دوجمله‌ای:

1. تعداد آزمایش‌ها ثابت باشد: تعداد افراد نمونه از قبل مشخص باشد.
2. هر آزمایش دو نتیجه داشته باشد: وقوع یا عدم وقوع رویداد.
3. آزمایش‌ها مستقل باشند: نتیجه یک آزمایش بر نتیجه آزمایش دیگر تأثیر نگذارد.
4. احتمال وقوع رویداد ثابت باشد: در تمام آزمایش‌ها مقدار p یکسان باشد.

- رویداد E را مورد بررسی قرار میدهیم.

N = 1233 , nE = 497 , P(E) = 497/1233 = 0.4031

متغییر تصادفی X = تعداد مردان در نمونه ای 10 نفره.

n = 10 , p=0.4031

در نتیجه:

X Binomial(10,0.4031)

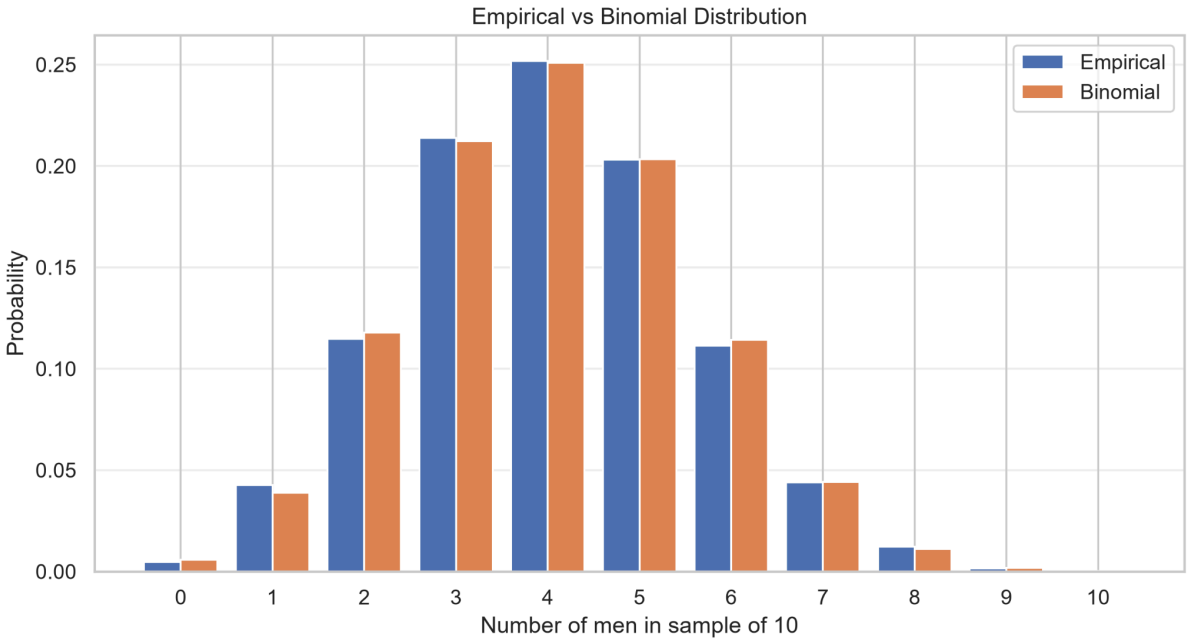
بررسی فروض مدل:

1. تعداد ازمایش ها ثابت و بررابر 10 مراجعه کننده است.
2. نتیجه دودویی است که یا مرد هست و یا خیر.
3. استقلال ازمایش ها: اگر افراد از یک جمعیت بزرگتر به صورت تصادفی انتخاب شوند میتوان استقلال رو تقریبی فرض کرد اما در این نمونه گیری بدون جایگذاری از 1233 نفر استقلال به طور کامل برقرار نیست.

و چون نسبت نمونه به کل برابر با 10/1233 = 0.0081 = 0.81% استو اسن نسبت کمتر از 5 درصده میتوان وابستگی ناشی از نمونه گیری بدون جایگذاری رو ناچیز دانست و مدل دوجمله ای را تقریب معقولی برای این متغییر تصادفی فرض کرد.

4. ثابت بودن احتمال: احتمال مرد بودن را با p تقریب میزنیم.

- در این مسئله، شمارش تعداد مراجعه‌کنندگان مرد در یک نمونه تصادفی ۱۰ نفره، یک متغیر گسسته مناسب برای مدل‌سازی با توزیع دوجمله‌ای است. با توجه به کوچک بودن نسبت حجم نمونه به جمعیت، فرض استقلال به‌صورت تقریبی قابل قبول است؛ هرچند مدل دقیق برای نمونه‌گیری بدون جایگذاری از جمعیت محدود، توزیع فوق‌هندسی (Hypergeometric) است.
- توزیع فوق‌هندسی: توزیع فوق‌هندسی احتمال تعداد وقوع یک رویداد دودویی را در نمونه‌ای با حجم ثابت که از یک جمعیت محدود و بدون جایگذاری انتخاب شده است، مدل می‌کند. این توزیع در مسئله حاضر دقیق‌تر از دوجمله‌ای است، زیرا انتخاب افراد بدون جایگذاری باعث تغییر احتمال مرد بودن در هر مرحله و وابستگی انتخاب‌ها می‌شود.



6. متغییر پیوسته و توزیع نرمال:

- **RH_ENTORHINAL_AVGTH**

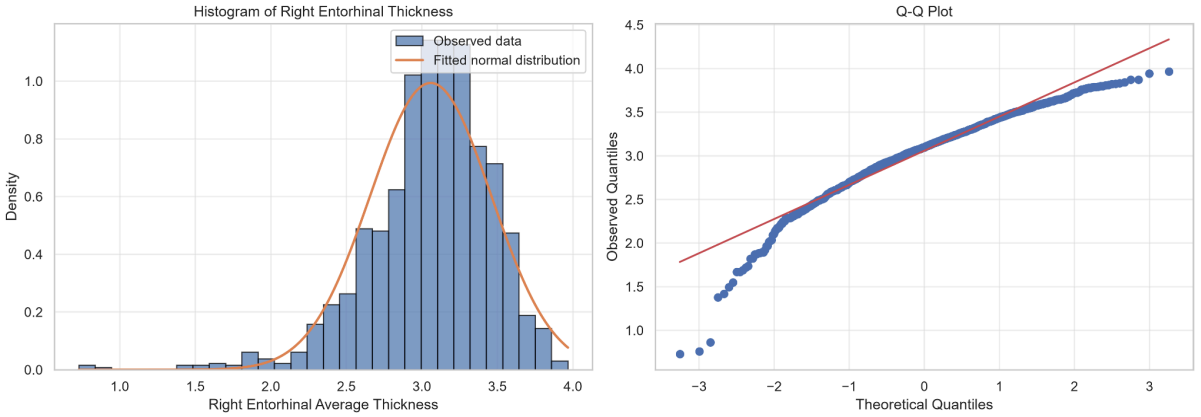
Descriptive Statistics: Number of observations: 1233 , Mean: 3.0584 , Standard deviation: 0.4014 , Median: 3.097 , ,Minimum: 0.729 , ,Maximum: 3.967 , First quartile (Q1): 2.856 , Third quartile (Q3): 3.321

Shapiro-Wilk Normality Test:

W statistic: 0.94782 , p-value:1.7611562053613604e-20 , Significance level: 0.05

Conclusion: Reject H0. There is evidence against normality.

Distribution Shape: Skewness: -1.1043 , Excess Kurtosis: 3.1072



توزیع این متغیر دارای چولگی منفی نسبتاً شدید است؛ بنابراین دنباله‌ی سمت چپ آن کشیده‌تر از سمت راست بوده و توزیع از حالت متقارن نرمال فاصله دارد. مقدار کشیدگی اضافی مثبت نشان‌دهنده‌ی دنباله‌های سنگین‌تر از توزیع نرمال است. در مجموع، این متغیر دارای عدم تقارن چپ و انحراف قابل توجه از نرمال بودن است.

LH_ENTORHINAL_AVGTH •

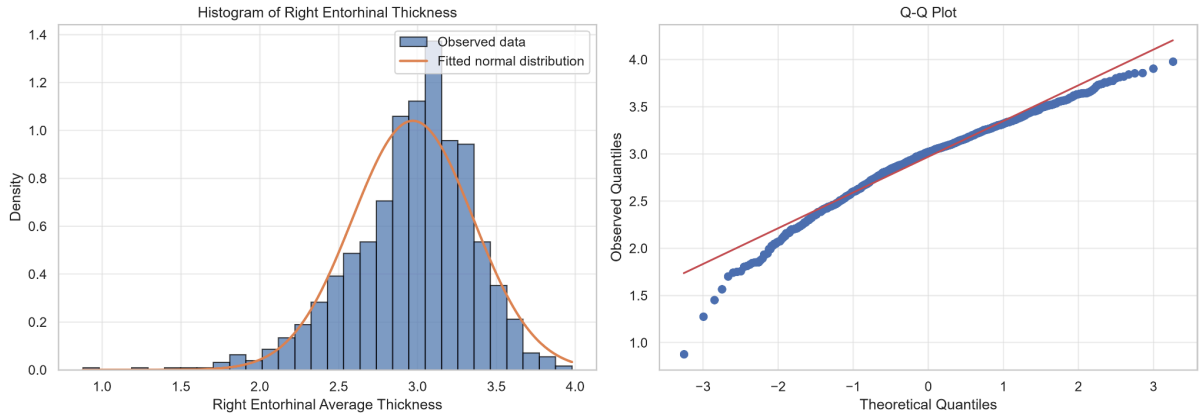
Descriptive Statistics: Number of observations: 1233 , Mean: 2.9703 , Standard deviation: 0.3836 , Median: 3.022 , ,Minimum: 0.878 , ,Maximum: 3.979 , First quartile (Q1): 2.764 , Third quartile (Q3): 3.228

Shapiro-Wilk Normality Test:

W statistic: 0.972 , p-value: 1.0280013838545035e-14 , Significance level: 0.05

Conclusion: Reject H0. There is evidence against normality.

Distribution Shape: Skewness: -0.7414 , Excess Kurtosis: 1.3573



این متغیر نیز دارای چولگی منفی است، اما شدت چولگی آن نسبت به متغیر RH_ENTORHINAL_AVGTH کمتر است؛ بنابراین عدم تقارن چپ در آن ملایم‌تر است. کشیدگی اضافی مثبت نشان می‌دهد که دنباله‌های توزیع نسبت به نرمال سنگین‌تر هستند، هرچند شدت این ویژگی از RH_ENTORHINAL_AVGTH کمتر است. در نتیجه، توزیع آن نسبت به متغیر اول متقارن‌تر بوده، اما همچنان نرمال نیست.

RH_ENTORHINAL_GVOL •

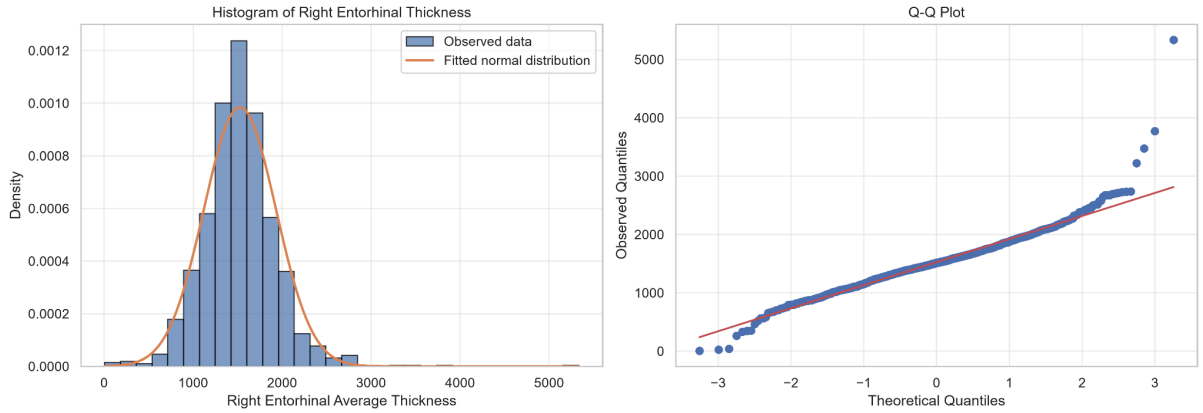
Descriptive Statistics: Number of observations: 1233 , Mean: 1526.1144 , Standard deviation: 405.3164 , Median: 1513.0 , Minimum: 6 , Maximum: 5334 , First quartile (Q1): 1290.0 , Third quartile (Q3): 1748.0

Shapiro-Wilk Normality Test:

W statistic: 0.94907 , p-value: 3.0893807785965976e-20 , Significance level: 0.05

Conclusion: Reject H0. There is evidence against normality.

Distribution Shape: Skewness: 0.9624 , Excess Kurtosis: 7.7656



این متغیر دارای چولگی مثبت نسبتاً شدید است و دنباله‌ی سمت راست آن کشیدگی قابل توجهی دارد. مقدار بسیار بالای کشیدگی اضافی نشان‌دهنده‌ی دنباله‌های بسیار سنگین‌تر از توزیع نرمال و احتمال وجود مقادیر دورافتاده در سمت راست توزیع است. در مقایسه با سه متغیر دیگر، RHGCOL بیشترین انحراف را از نظر سنگینی دنباله‌ها نشان می‌دهد.

LH_ENTORHINAL_GVOL •

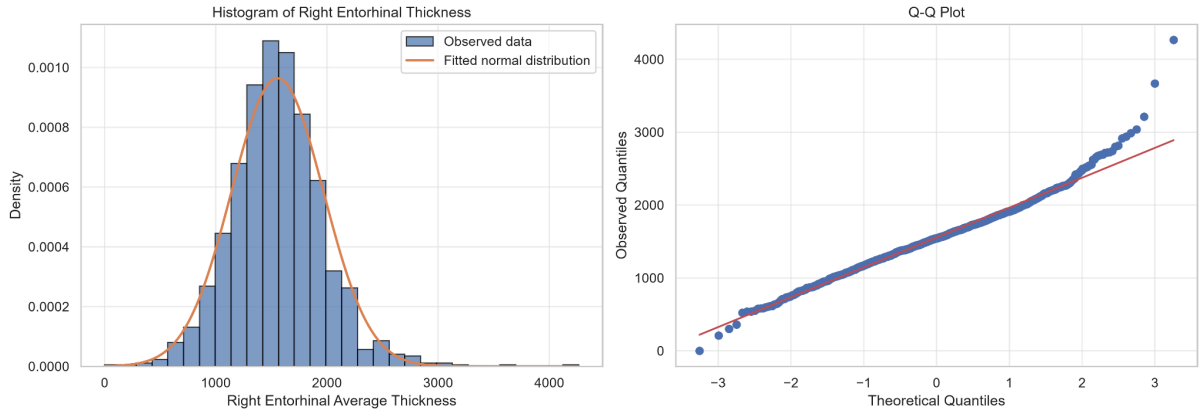
Descriptive Statistics: Number of observations: 1233 , Mean: 1554.6058 , Standard deviation: 413.9371 , Median: 1545.0 , Minimum: 0 , Maximum: 4265 , First quartile (Q1): 1295.0 , Third quartile (Q3): 1785.0

Shapiro-Wilk Normality Test:

W statistic: 0.97765 , p-value: 7.002294457757457e-13 , Significance level: 0.05

Conclusion: Reject H0. There is evidence against normality.

Distribution Shape: Skewness: 0.5265 , Excess Kurtosis: 2.5438



توزیع این متغیر دارای چولگی مثبت ملایم است؛ بنابراین دنباله‌ی سمت راست آن کمی کشیده‌تر از سمت چپ بوده و نسبت به دو متغیر اول جهت عدم تقارن متفاوتی دارد. کشیدگی اضافی مثبت نشان‌دهنده‌ی دنباله‌های سنگین‌تر از توزیع نرمال است. در مجموع، این متغیر از نظر چولگی به حالت متقارن نزدیک‌تر است، اما از نظر کشیدگی همچنان با توزیع نرمال تفاوت دارد.

در نمودار Q-Q Plot، نزدیک بودن نقاط به خط مرجع نشان‌دهنده‌ی سازگاری داده‌ها با توزیع نرمال است. اگر نقاط در اطراف خط و بدون الگوی مشخص پراکنده باشند، توزیع تقریباً نرمال در نظر گرفته می‌شود. در صورت ایجاد انحنای سیستماتیک، توزیع از نرمال بودن فاصله دارد؛ به‌طوری‌که الگوی S شکل می‌تواند نشان‌دهنده‌ی تفاوت در سنگینی دنباله‌ها نسبت به توزیع نرمال باشد. اگر نقاط در سمت چپ خط و در بخش پایین نمودار انحراف بیشتری داشته باشند، ممکن است دنباله‌ی چپ سنگین‌تر یا چولگی منفی وجود داشته باشد؛ در مقابل، انحراف بیشتر در بخش بالایی نمودار می‌تواند نشان‌دهنده‌ی دنباله‌ی راست سنگین‌تر یا چولگی مثبت باشد. همچنین فاصله‌ی زیاد نقاط انتهایی از خط مرجع می‌تواند نشان‌دهنده‌ی وجود مقادیر دورافتاده یا دنباله‌های سنگین باشد. در توزیع‌های دارای چولگی مثبت، نقاط انتهایی سمت راست معمولاً بالاتر از خط مرجع قرار می‌گیرند و در چولگی منفی، انحراف در سمت چپ بیشتر دیده می‌شود. اگر نقاط در بخش مرکزی نزدیک خط باشند اما در دو انتها فاصله بگیرند، ممکن است مرکز توزیع تقریباً نرمال باشد ولی دنباله‌ها با نرمال تفاوت داشته باشند. بنابراین، تفسیر Q-Q Plot باید با توجه به الگوی کلی نقاط، میزان انحراف از خط، چولگی و کشیدگی انجام شود و در کنار آزمون Shapiro-Wilk و هیستوگرام مورد استفاده قرار گیرد.

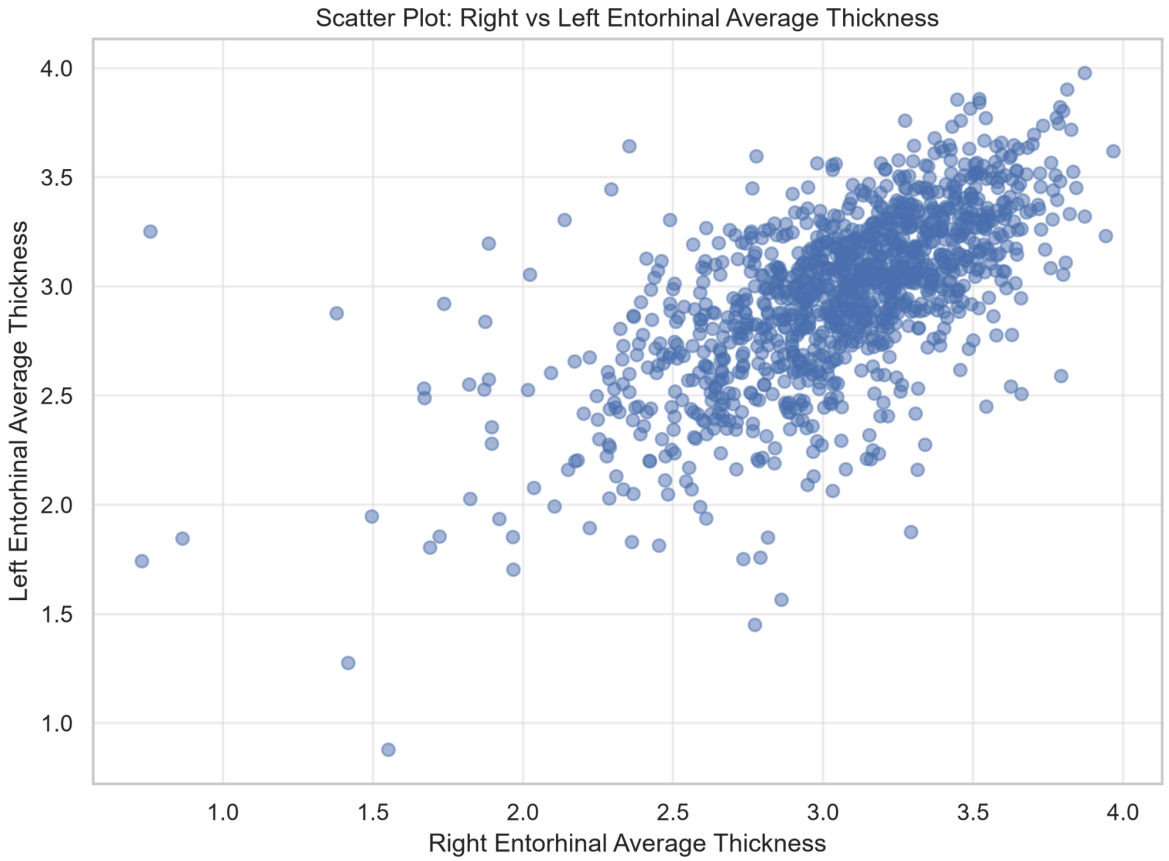
7. امیدریاضی و واریانس:

- در بخش قبل میانگین و انحراف معیار های 4 متغییر اصلی را محاسبه کرده ایم.
- برای متغیر RH_ENTORHINAL_AVGTH میانگین نمونه برابر با 3.0584 و واریانس نمونه برابر با 0.16112 محاسبه شد. میانگین نشان‌دهنده‌ی مقدار متوسط ضخامت ناحیه‌ی انتورینال در نیم‌کره‌ی راست مغز در میان افراد مورد بررسی است. واریانس میزان پراکندگی مقادیر ضخامت را حول میانگین نشان می‌دهد؛ به‌طوری‌که واریانس کوچک‌تر بیانگر تمرکز بیشتر داده‌ها در اطراف میانگین و واریانس بزرگ‌تر بیانگر پراکندگی بیشتر است. در این نمونه، واریانس برابر با 0.16112 نشان می‌دهد که مقادیر ضخامت دارای پراکندگی مشخصی نسبت به میانگین هستند. از آنجا که واریانس بر حسب مربع واحد اندازه‌گیری متغیر بیان می‌شود، تفسیر آن از انحراف معیار کمتر مستقیم است.

8.دو متغییر تصادفی و کواریانس:

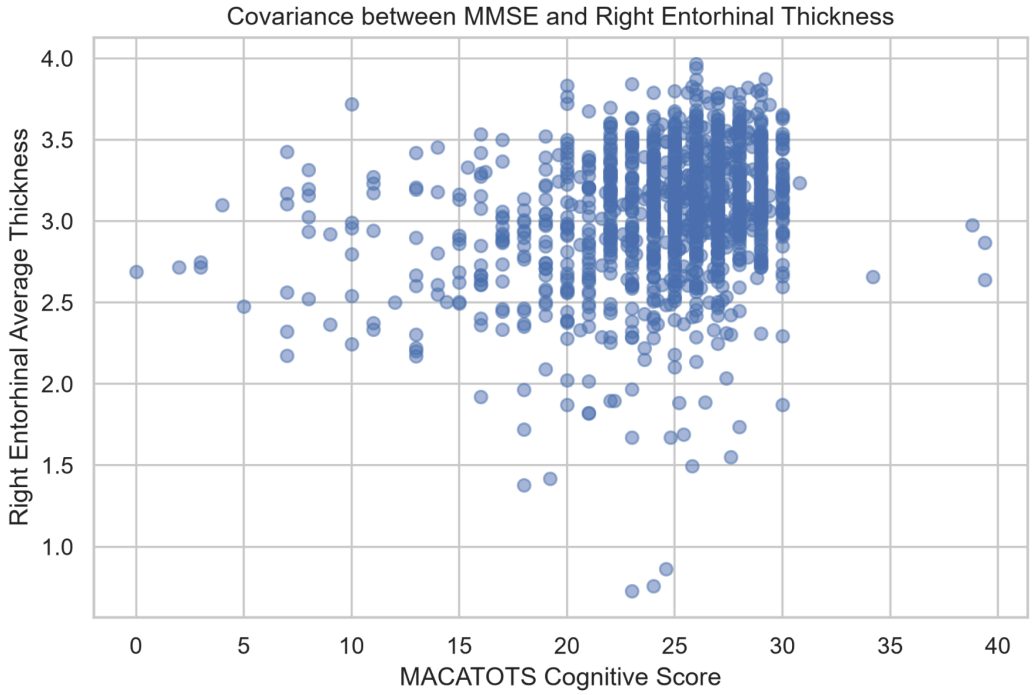
- رابطه ی بین میانگین ضخامت قشر انتوریال چپ و راست:

Covariance: 0.099075643066483



- رابطه ی بین متغییر ازمون شناختی MOCATOTS و میانگین ضخامت قشر انتوریال راست:

Covariance: 0.454155968180238 23



- کوواریانس مثبت بین میانگین ضخامت قشر انتوریال چپ و راست (0.099) نشان می‌دهد که ضخامت این دو ناحیه تمایل دارند در یک جهت تغییر کنند. همچنین کوواریانس مثبت بین نمره‌ی آزمون شناختی MOCATOTS و ضخامت قشر انتوریال راست (0.454) بیانگر هم‌جهتی تغییرات این دو متغیر است. مقدار کوواریانس رابطه‌ی دوم بزرگ‌تر است، اما به دلیل تفاوت مقیاس متغیرها نمی‌توان شدت روابط را مستقیماً مقایسه کرد. این نتایج می‌توانند نشان‌دهنده‌ی ارتباط میان ساختار مغز و عملکرد شناختی باشند، اما برای بررسی دقیق‌تر، محاسبه‌ی ضریب همبستگی و کنترل عوامل مخدوش‌کننده ضروری است.

9.قضیه بیز، در صورت تناسب:

A: نمره‌ی MOCATOTS فرد پایین‌تر یا مساوی میانه‌ی نمونه باشد.

B: ضخامت قشر انتوریال راست فرد پایین‌تر از میانه‌ی نمونه باشد.

می‌خواهیم احتمال پایین بودن نمره‌ی شناختی را با دانستن پایین بودن ضخامت MRI محاسبه کنیم:

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

P(A): 0.5028386050283861

P(B): 0.497972424979724 27

P(B | A): 0.5709677419354838

P(A | B): 0.5765472312703582

احتمال پایین بودن نمره‌ی شناختی در کل نمونه برابر با حدود ۵۰٫۳٪ است؛ درحالی‌که احتمال آن در میان افرادی با ضخامت پایین قشر انتوریال راست به ۵۷٫۷٪ می‌رسد.بنابراین، مشاهده‌ی ضخامت پایین این ناحیه با افزایش حدود ۷٫۴ واحد درصدی احتمال نمره‌ی شناختی پایین همراه است.این نتیجه نشان‌دهنده‌ی ارتباط آماری بین ضخامت قشر انتوریال راست و عملکرد شناختی است، اما به‌تنهایی رابطه‌ی علّی را اثبات نمی‌کند.

الزامات مسیر ج:

1.احتمال شرطی و وضعیت شناختی:

A: فرد دارای نمره‌ی شناختی پایین است؛ یعنی MOCATOTS کمتر یا مساوی میانه‌ی نمونه است.

B_1: ضخامت قشر انتوریال راست کمتر از میانه‌ی نمونه است.

B_2: ضخامت قشر انتوریال راست بیشتر یا مساوی میانه‌ی نمونه است.

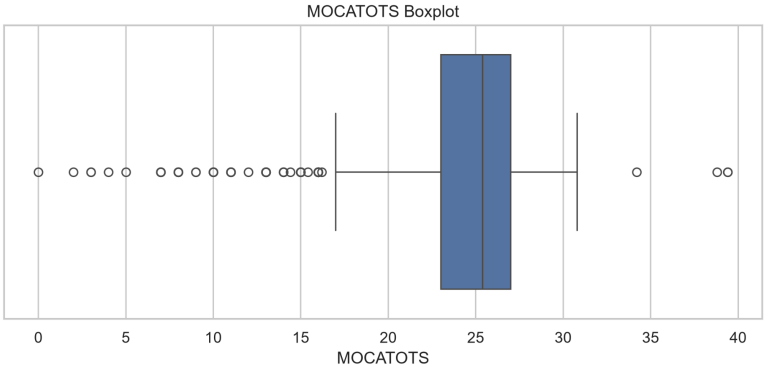
$$P(A|B_1), P(A|B_2)$$

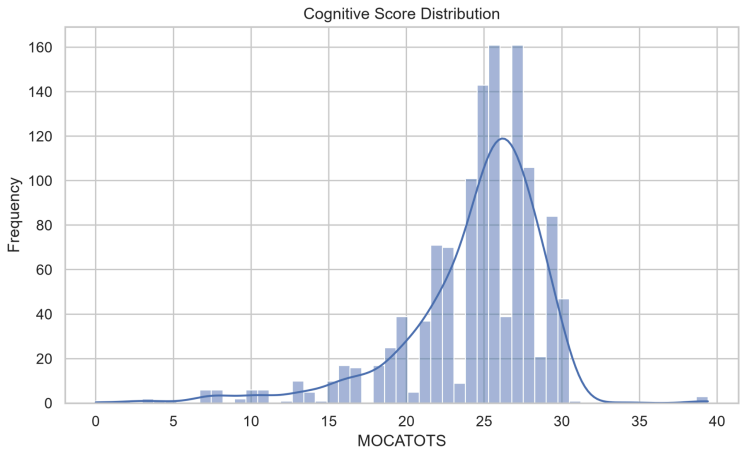
احتمال نمره‌ی شناختی پایین (MOCATOTS ≤ 25.4) در گروه دارای ضخامت پایین قشر انتوریال راست، برابر با ۵۸٪ و در گروه دارای ضخامت بالا، برابر با ۴۳٪ به دست آمد.این اختلاف ۱۵ واحد درصدی نشان می‌دهد که نمره‌ی شناختی پایین در گروه با ضخامت کمتر این ناحیه، فراوانی بیشتری دارد.

2. توزیع یک نمره شناختی و یک متغییر MRI:

- متغیر شناختی از UDS: `MOCATOTS` — نمره آزمون شناختی.

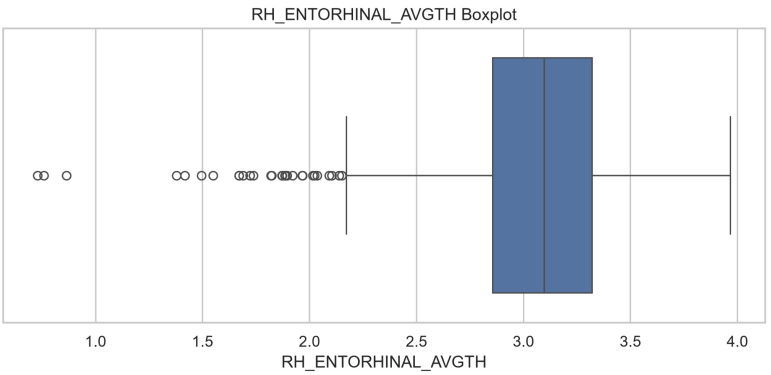
توزیع متغیر شناختی **MOCATOTS** با استفاده از نمودار هیستوگرام بررسی شد. میانگین نمرات برابر با 24.44 و واریانس نمونه‌ای برابر با 20.14 به دست آمد. میانه نمرات 25.4 و انحراف معیار 4.49 است. مقدار چولگی برابر با 1.68- نشان‌دهنده توزیع چوله به چپ است. همچنین با استفاده از روش IQR، تعداد 80 نقطه دورافتاده شناسایی شد که نشان‌دهنده وجود مقادیر غیرمعمول در نمرات شناختی است.

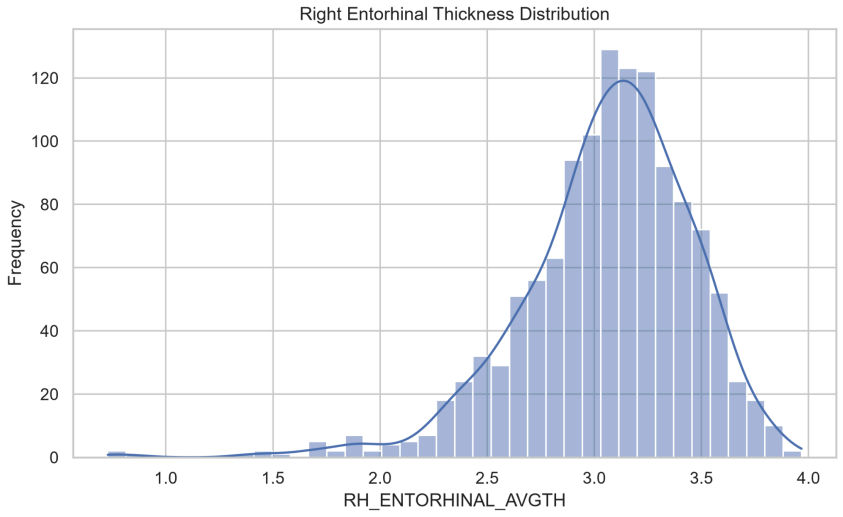




- متغیر `RH_ENTORHINAL_AVGTH` :MRI — میانگین ضخامت قشر انتورینال سمت راست مغز.

توزیع متغیر MRI یعنی RH_ENTORHINAL_AVGTH با استفاده از نمودار هیستوگرام بررسی شد. میانگین ضخامت قشر انتورینال سمت راست برابر با 3.058 و واریانس نمونه‌ای آن برابر با 0.161 به دست آمد. میانه داده‌ها 3.097 و انحراف معیار برابر با 0.401 است. مقدار چولگی 1.106- نشان‌دهنده چولگی به چپ در توزیع داده‌ها است. همچنین با استفاده از روش IQR، تعداد 30 نقطه دورافتاده شناسایی شد.





3.احتمال مشترک دو وجه: تسک های 2 و 3 مشترک همین کار را انجام دادیم.

4.کواریانس شناخت و تصویربرداری: در تسک 8 مشترک انجام شده.

5.کنترل مراجعه تکراری:

با توجه به ساختار داده‌های NACC، ممکن است برای هر شرکت‌کننده چندین مراجعه در زمان‌های مختلف ثبت شده باشد؛ بنابراین، وجود مراجعات تکراری می‌تواند استقلال مشاهدات را نقض کند. برای کنترل این مسئله، شناسه شرکت‌کنندگان (NACCID) بررسی شد تا هر فرد در تحلیل‌های اصلی تنها یک بار لحاظ شود. قاعده انتخاب مراجعه شاخص به‌صورت انتخاب اولین مراجعه دارای داده‌های معتبر و قابل استفاده برای متغیرهای شناختی و MRI تعریف شد. در صورت وجود چند مراجعه واجد شرایط، مراجعه با زمان ثبت زودتر انتخاب گردید. سایر مراجعات تکراری از مجموعه تحلیل اصلی کنار گذاشته شدند. این روش باعث می‌شود واحد تحلیل، شرکت‌کننده مستقل باشد و از شمارش چندباره افراد جلوگیری شود.